

Momento de Retroalimentación: Módulo 2 Implementación de una técnica de aprendizaje máquina sin el uso de un framework. (Portafolio Implementación)

Mauricio Guerrero González A01751436

Grupo 601

Jorge Adolfo Ramírez Uresti

Instituto Tecnológico de Estudios Superiores de Monterrey

10 de septiembre del 2026

1. Dataset empleado

El algoritmo fue entrenado y evaluado utilizando el dataset “Titanic - Machine Learning from Disaster” de Kaggle. Específicamente, se utilizó el archivo `train.csv`, el cual contiene 891 registros correspondientes a pasajeros del Titanic y diferentes características relacionadas con cada observación.

La variable objetivo utilizada para la clasificación es `Survived`. Esta variable indica si el pasajero sobrevivió al desastre, donde el valor 0 representa que no sobrevivió y el valor 1 representa que sí sobrevivió. Por lo tanto, el objetivo del árbol de decisión consiste en identificar patrones dentro de las características de los pasajeros que permitan determinar la clase correspondiente.

Para evaluar el desempeño del algoritmo, el dataset se divide de forma aleatoria en dos subconjuntos. El 80 % de los registros se utiliza para entrenar el modelo y el 20 % restante se utiliza para realizar la prueba. De esta manera, una parte de los datos permanece separada durante la construcción del árbol y permite evaluar su comportamiento sobre observaciones que no fueron utilizadas directamente durante el entrenamiento.

2. Preparación de los datos

Antes de construir el árbol se realiza una preparación de las variables utilizadas como entrada. Se seleccionan las características `Pclass`, `Sex`, `Age`, `SibSp`, `Parch` y `Fare`, debido a que representan información relevante sobre la clase del pasajero, su sexo, edad, familiares a bordo y tarifa pagada.

Además de las variables originales, se construyen dos variables adicionales. La primera es `FamilySize`, que representa el tamaño total de la familia y se obtiene a partir de `SibSp` y `Parch`. La segunda es `IsAlone`, que indica si el pasajero viajaba solo.

Cabe mencionar que la variable `Sex` se transforma a valores numéricos para poder ser utilizada directamente por el árbol de decisión. En esta transformación, el valor 0 representa a los pasajeros masculinos y el valor 1 representa a las pasajeras femeninas. También se consideran los valores faltantes presentes en las variables numéricas. Para evitar que estos valores impidan la construcción del árbol, se reemplazan utilizando la mediana calculada a partir del conjunto de entrenamiento. De esta manera, el procedimiento de preparación de los datos utiliza únicamente información disponible dentro del conjunto utilizado para construir el modelo.

3. Implementación del árbol de decisión

El árbol de decisión se implementa completamente desde cero, sin utilizar un framework o biblioteca especializada de aprendizaje máquina para construir el modelo. La finalidad de esta implementación es reproducir los principales pasos que realiza un árbol de decisión y comprender cómo se determina cada división. El primer componente utilizado para seleccionar las divisiones

es el índice Gini. Esta medida permite determinar qué tan mezcladas se encuentran las clases dentro de un nodo. Cuando las observaciones pertenecen principalmente a una sola clase, la impureza disminuye. Por el contrario, cuando las clases se encuentran más mezcladas, el valor del índice Gini aumenta.

Para cada variable se prueban diferentes puntos de corte y se calcula el Gini resultante después de dividir los datos. La división seleccionada corresponde a aquella que produce la menor impureza ponderada entre los nodos resultantes. Una vez identificada la mejor división, el procedimiento se repite para cada una de las ramas. El árbol continúa construyéndose hasta alcanzar alguna de las condiciones establecidas, como una profundidad máxima, un número mínimo de observaciones o un nodo completamente puro.

Configuración	Valor
Profundidad máxima	4
Mínimo de muestras para dividir	30
Mínimo de muestras por hoja	15
Criterio de división	Índice Gini

Tabla 1: Configuraciones principales utilizadas durante la construcción del árbol.

La tabla anterior resume las condiciones establecidas para controlar la construcción del modelo.

4. Generación del árbol y predicciones

Después de entrenar el modelo con el conjunto correspondiente, el árbol genera una estructura compuesta por diferentes condiciones de decisión. Cada nodo representa una comparación sobre una variable y cada rama corresponde al resultado de dicha comparación.

La siguiente figura corresponde a la estructura obtenida al ejecutar el algoritmo. Esta representación permite observar directamente las reglas que fueron generadas a partir de los datos de entrenamiento.




Figura 1: Estructura del árbol de decisión generado durante el entrenamiento.

Para comprobar el funcionamiento del modelo, también se generan predicciones sobre observaciones del conjunto de prueba. La siguiente tabla muestra ejemplos de las clases reales y las predicciones generadas.

Observación	1	2	3	4	5	6	7	8	9	10
Real	0	0	1	0	1	1	1	0	0	0
Predicción	0	0	0	0	1	0	1	0	0	0
Observación	11	12	13	14	15	16	17	18	19	20
Real	0	0	1	0	0	0	0	0	0	1
Predicción	0	0	0	0	0	0	0	0	0	1

Tabla 2: Ejemplos de predicciones generadas sobre observaciones del conjunto de prueba.

La comparación muestra que algunas observaciones son clasificadas correctamente mientras que otras presentan diferencias entre la clase real y la predicción.

5. Resultados de evaluación

Para evaluar el desempeño del árbol se utilizan cuatro métricas de clasificación: Accuracy, Precision, Recall y F1-score. Cada una proporciona información diferente acerca del comportamiento del modelo.

El Accuracy representa la proporción de observaciones clasificadas correctamente respecto al total. La Precision indica qué proporción de las observaciones clasificadas como sobrevivientes realmente pertenece a esa clase. El Recall muestra qué proporción de los pasajeros que realmente sobrevivieron fue identificada correctamente. Finalmente, el F1-score combina Precision y Recall para obtener una medida conjunta de ambas.

Los resultados obtenidos tanto para entrenamiento como para prueba se presentan a continuación.

Métrica	Entrenamiento	Prueba
Accuracy	0.8301	0.7318
Precision	0.7533	0.6265
Recall	0.8278	0.7536
F1-score	0.7888	0.6842

Tabla 3: Métricas obtenidas por el árbol de decisión en los conjuntos de entrenamiento y prueba.

Los resultados muestran que el modelo obtiene un mejor desempeño sobre los datos utilizados

durante el entrenamiento. En el conjunto de prueba, todas las métricas presentan una disminución, lo cual es esperado cuando el modelo se evalúa sobre observaciones que no participaron directamente en su construcción.

El Accuracy disminuye de 0.8301 a 0.7318. De forma similar, Precision pasa de 0.7533 a 0.6265, Recall disminuye de 0.8278 a 0.7536 y F1-score pasa de 0.7888 a 0.6842.

A pesar de que existe una diferencia entre ambos conjuntos, las métricas de prueba muestran que el árbol conserva una capacidad razonable para identificar patrones relacionados con la supervivencia.

6. Matriz de confusión

La matriz de confusión permite observar con mayor detalle cómo se distribuyen las predicciones correctas e incorrectas del modelo.

Para el conjunto de prueba se obtuvieron 52 verdaderos positivos, 79 verdaderos negativos, 31 falsos positivos y 17 falsos negativos. Los verdaderos positivos corresponden a pasajeros que sobrevivieron y fueron correctamente clasificados como sobrevivientes. Los verdaderos negativos corresponden a pasajeros que no sobrevivieron y fueron correctamente clasificados como no sobrevivientes.

Por otra parte, los falsos positivos corresponden a casos en los que el modelo predijo supervivencia cuando en realidad el pasajero no sobrevivió. Los falsos negativos representan pasajeros que sí sobrevivieron, pero que fueron clasificados como no sobrevivientes.




Figura 2: Matriz de confusión obtenida sobre el conjunto de prueba.

De acuerdo con la matriz presentada, el modelo clasifica correctamente 131 de las 179 observaciones de prueba, resultado que corresponde a la suma de los 52 verdaderos positivos y los 79 verdaderos negativos.

Los 31 falsos positivos representan una parte importante de los errores cometidos por el modelo. Sin embargo, el número de falsos negativos es menor, con 17 casos. Esta diferencia también se refleja en el Recall obtenido, que es superior a la Precision.

7. Justificación de las métricas

El Accuracy de 0.7318 indica que el modelo clasificó correctamente el 73.18 % de las observaciones del conjunto de prueba, lo cual significa que aproximadamente siete de cada diez pasajeros fueron clasificados correctamente por el árbol.

Por otro lado, la métrica Precision de 0.6265 indica que, de todas las observaciones que el modelo clasificó como sobrevivientes, el 62.65 % realmente pertenecía a esa clase. El valor se encuentra por debajo del Accuracy debido a la presencia de 31 falsos positivos.

El Recall de 0.7536 es la métrica más alta obtenida en el conjunto de prueba. Este resultado indica que el modelo identificó correctamente aproximadamente el 75.36 % de los pasajeros que realmente sobrevivieron; la cantidad de 17 falsos negativos contribuye a que este valor sea relativamente alto.

Por último, el F1-score de 0.6842 proporciona una medida conjunta entre Precision y Recall. Su valor refleja el equilibrio entre ambas métricas y muestra que, aunque el modelo tiene una capacidad razonable para identificar a los pasajeros sobrevivientes, todavía existen errores de clasificación que reducen su desempeño general.

En este caso tanto la matriz de confusión como las métricas permiten justificar que el desempeño del modelo es aceptable para una primera implementación. La mayoría de las observaciones fueron clasificadas correctamente y el Recall muestra que el árbol logra identificar una proporción importante de los pasajeros que efectivamente sobrevivieron.

9. Conclusión

El árbol de decisión implementado desde cero cumple con el objetivo de clasificar a los pasajeros del Titanic de acuerdo con su probabilidad de supervivencia. El proceso incluye la preparación de los datos, la creación de variables adicionales, el cálculo del índice Gini, la búsqueda de divisiones y la construcción recursiva de las ramas hasta obtener una predicción.

Los resultados obtenidos muestran un desempeño aceptable para la implementación realizada. Sobre el conjunto de prueba, el modelo alcanza un Accuracy de 73.18 %, una Precision de 62.65 %, un Recall de 75.36 % y un F1-score de 68.42 %. Por otro lado, la matriz de confusión confirma que fueron mayoría las clasificaciones correctas, con 52 verdaderos positivos y 79 verdaderos negativos. Al mismo tiempo, los 31 falsos positivos y 17 falsos negativos muestran que todavía existen errores de clasificación que pueden ser reducidos mediante ajustes al modelo.

La disminución de las métricas respecto al conjunto de entrenamiento evidencia que el modelo no obtiene el mismo desempeño al enfrentarse a datos nuevos. Sin embargo, la diferencia observada es razonable y el árbol conserva una capacidad útil para detectar patrones relacionados con la supervivencia.

Finalmente, aunque la implementación logra resolver la tarea de clasificación, su desempeño podría mejorar mediante ajustes en la profundidad del árbol, los criterios de división, los parámetros mínimos de las hojas y las variables utilizadas. Estos cambios permitirían explorar configuraciones diferentes y determinar si es posible aumentar el desempeño del modelo sobre observaciones nuevas.